

Dr. Youcef SKLAB

IRD – Sorbonne Université

Proposition de Sujet de Projet de Fin d'Études (PFE)

Titre du PFE :

Apprentissage Multi-Branches Guidé par la Segmentation et la Détection d'Organes pour la Classification de Traits Morphologiques à partir d'Images d'Herbiers

Contexte :

L'analyse automatisée des spécimens d'herbiers numérisisés (Figure 1) permet d'accélérer les études botaniques à grande échelle. Cependant, les modèles de deep learning peuvent apprendre à partir de biais de fond (fond de l'image, étiquettes, artefacts) plutôt que de se concentrer sur les zones pertinentes de la plante (Figure 2). Des travaux récents ont montré que l'intégration de la segmentation des plantes (Figure 3) et la détection d'organes (feuilles, fleurs, tiges, fruits, etc.) améliore significativement la performance, l'interprétabilité et la robustesse des modèles (Figure 4).




Figure 1 : Exemples d'images d'herbiers illustrant la grande hétérogénéité des fonds, des supports, de l'état de conservation et de la disposition des plantes. On observe des variations notables dans la texture du papier, la présence d'étiquettes manuscrites ou imprimées, de montages (bandes, ficelles, enveloppes), ainsi que dans les angles de vue et l'éclairage. Cette diversité rend la tâche de classification et d'analyse par deep learning particulièrement complexe

Problématique :

Comment développer un modèle de classification robuste qui intègre à la fois l'image originale, l'image segmentée (masque de plante), et les résultats de détection d'organes, dans un cadre d'apprentissage multi-branches, pour renforcer l'attention du modèle sur les régions botaniquement pertinentes ?




Figure 2 : **Les modèles de deep learning peuvent apprendre pour de mauvaises raisons** - Illustration du processus de classification automatisée d'images d'herbiers par un modèle de deep learning. Les cartes d'attention (heatmaps) générées révèlent que le modèle porte souvent son attention sur l'arrière-plan (étiquettes, rubans, textures du papier) plutôt que sur les organes végétaux eux-mêmes. Ce phénomène de « mauvaise attention » limite la généralisation du modèle et nuit à l'interprétabilité biologique des résultats.

Objectifs :

- Proposer une architecture multi-branches (basée sur ViT ou CNN + ViT).
- Exploiter conjointement :
 - l'image brute de l'herbier;
 - le masque de segmentation de la plante (guidage spatial);
 - les résultats de détection d'organes (guidage sémantique)
- Intégrer des mécanismes d'attention ou de pondération de patches guidés par les masques.
- Évaluer la robustesse et l'interprétabilité des modèles en présence de bruit.
- Comparer avec des architectures mono-branch (baseline).




Figure 3 : Exemples de segmentation d'images d'herbiers à l'aide de masques générés à partir de détections par boîtes englobantes (bbox prompts). La segmentation permet d'éliminer efficacement les éléments non pertinents du fond (étiquettes, règle, texte, couleur du papier), afin de ne conserver que les parties végétales. Cela recentre l'attention des modèles de classification sur les structures biologiques d'intérêt.

Résultats Attendus :

- Amélioration significative de la précision de classification pour des traits botaniques fins.
- Meilleure concentration des cartes d'attention sur les régions d'intérêt (évaluées par Grad-CAM ou attention maps).
- Démonstration de la robustesse aux perturbations (bruit, fond modifié).
- Proposition d'un framework réutilisable pour d'autres tâches (e.g., reconnaissance de taxons, analyse de phénologie).




Figure 4 : **Effet de la segmentation sur l'attention des modèles.** Les cartes d'attention générées avant (en haut) et après segmentation (en bas) montrent que sans guidage, le modèle peut être distrait par des éléments non pertinents de l'image (ex. étiquettes, rubans, textures). En revanche, l'utilisation d'un masque de segmentation force le modèle à se concentrer sur les régions végétales pertinentes, améliorant ainsi la qualité de l'apprentissage et l'interprétabilité des prédictions.

Technologies et Outils :

- Python, PyTorch,
- Vision Transformers (DeiT, CrossViT, AT-ViT)
- YOLOv7-ag pour la détection d'organes

dataset :
<https://filesender.renater.fr/?s=download&token=3761d737-364c-43d8-8093-0950d47f1c90>

Yolov7-ag

plant Sam <https://github.com/IA-E-Col/PlantSAM>

Etudier le dataset voire nb organne ...
implémenter une première version